

# Soru-2

Bu çalışma kapsamında sizden Transformer tabanlı modeller hakkında son 3 yıl içinde çıkmış farklı iki makalenin özetini yazmanızı bekliyoruz.

## *Makale 1 - Transformer (Dönüştürücü) Mimarisi Kullanarak*

### *Zaman Serilerinde Anomali Tespiti*

**Çifçi, O. S. (2023). Transformer mimarisi kullanarak zaman serilerinde anomali tespiti.**

**Bozok Journal of Engineering and Architecture, 3(3), 1-15.**

**<https://dergipark.org.tr/tr/download/article-file/2930533>**

Bu çalışma, zaman serisi verilerinde anomali tespiti için Transformer tabanlı modellerin kullanımını incelemektedir. Geleneksel yöntemlerin uzun bağımlılıkları öğrenmede ve büyük veri setlerini işlemede yetersiz kalması nedeniyle, paralel hesaplama yeteneğine sahip Transformer mimarisinin avantajları vurgulanmaktadır. LSTM ve CNN gibi yöntemlerle karşılaştırıldığında, Transformer tabanlı modellerin daha yüksek doğruluk ve düşük hesaplama maliyeti sunduğu belirtilmektedir. Çalışma, Sanayi 4.0 uygulamalarında büyük veri setleri üzerinde anomali tespitinin hızlandırılmasına yönelik bir çözüm önerisi sunmaktadır.

Problem tanımı olarak, bir  $T$  zaman serisi eğitim girdisi olarak verildiğinde eğitim serisiyle aynı modaliteye sahip önceden sistemin görmediği herhangi bir  $T$  test zaman serisi için,  $y = \{y_1, \dots, y_T\}$  tahminini elde etmemiz gerekir. 1 sayısı anomali bir veri noktasını belirtmektedir ve 0 sayısı da normal bir veri noktasını belirtir. Verimiz çeşitli veri ön işleme süreçlerinden geçmiştir. Bunlardan birincisi 25 boyutlu verimizi PCA yöntemi ile 4 boyuta indirgedik. Ardından, eğitim kümesindeki verileri her bir kolondaki minimum ve maksimum değerlerini gözönünde bulundurarak normalleştirdik ve son olarak hem eğitim hem de test için zaman serisi pencerelerine dönüştürdük.

Bu çalışmada, TranAD modelinin Transformer tabanlı bir kodlayıcı-kod çözücü mimarisi kullanarak zaman serilerinde anomali tespiti yaptığı açıklanmaktadır. Model, giriş dizisini dikkat mekanizmalarından geçirerek anomali tespitini optimize eder. Çok başlı öz dikkat (multi-head self-attention) mekanizması kullanılarak, farklı temsil alt uzaylarından gelen bilgilerin paralel şekilde işlenmesi sağlanır. Modelin eğitimi, GAN tabanlı çekişmeli bir yöntemle gerçekleştirilir ve böylece anomali tespit performansı artırılır. Ayrıca, kod çözücülerin gelecekteki zaman damgalarını görmesini engellemek amacıyla bir maskeleye yöntemi uygulanır. Son aşamada, sigmoid aktivasyon fonksiyonu ile çıktı değerleri 0 ile 1 arasına çekilir, bu da anomali olasılıklarının belirlenmesini sağlar.

Önceden görülmemiş bir veri için  $((W, C))$  anomali skoru aşağıdaki gibi ifade edilir:

$$s = \frac{1}{2} \|o_1 - \hat{W}\|_2 + \frac{1}{2} \|\hat{o}_2 - \hat{W}\|_2$$

Test süresindeki çıkarım yine iki aşamada çalışır ve dolayısıyla tek bir yeniden yapılandırma çifti elde ederiz ( $O_1$  ve  $O_2$ ). Test zamanında, sadece mevcut zaman damgasına kadar olan veriler dikkate alınır ve bu nedenle bu işlem sıralı olarak çalışır. Bir zaman damgasında her boyut için anomali puanlarına ( $s_i$ ) sahip olduğumuzda, elde edilen bu puan belirlenen eşikten büyükse, zaman damgası anomali olarak etiketlenir.

Elde edilen veriler, literatürde kullanılan modeller ile karşılaştırılmıştır. Karşılaştırma için 3 ayrı metrik kullanılmıştır. Bunlardan birincisi kesinlik, yani gerçek pozitiflerin gerçek pozitifler ve yanlış pozitiflere oranı, ikincisi duyarlılık, yani gerçek pozitiflerin gerçek pozitifler artı yanlış negatiflere oranıdır. Son metrik ise, hem kesinliğin hem de duyarlılığın etkisi olduğu ve genellikle daha geçerli bir metrik olarak kabul edilen F1 skorudur. Karşılaştırma sonuçları aşağıdaki tabloda gösterilmektedir.

Model	Kesinlik (Precision)	Duyarlılık (Sensitivity)	F1 Skoru
OCSVM	62.75	80.89	70.67
Isolation Forest	76.09	92.45	83.48
LOF [14]	57.89	90.49	70.61
Deep-SVDD [19]	95.41	86.49	90.73
DAGMM [16]	93.49	70.03	80.08
MMPACD [17]	76.26	78.35	77.29
VAR	90.71	83.82	87.13
LSTM [40]	76.93	89.64	82.80
CL-MPPCA	56.02	99.93	71.80
ITAD [21]	72.80	64.02	68.13
LSTM-VAE [22]	73.62	89.92	80.96
BeatGAN [25]	90.30	93.84	92.04
OmniAnomaly [2]	88.39	74.46	80.83
InterFusion [23]	83.61	83.45	83.52
THOC [20]	88.14	90.99	89.54
<b>Bu Çalışma</b>	<b>65.62</b>	<b>92.56</b>	<b>76.79</b>

Şekil-1 – Karşılaştırma sonuçlarının tablo gösterimi

Sonuç olarak, uzun bir süredir pekçok kişinin üzerinde çalıştığı ve finanstan bilgi teknolojilerine, sanayiden çevre sağlığına kadar çeşitli sektörleri kapsayan çok değişkenli zaman serilerinde anomali tespiti yapabilen dönüştürücü tabanlı ve çekişmeli eğitim süreci izleyen bir model daha hızlı olabilmesi için modifiye edildi.

## ***Makale 2 - AKCİĞER GÖRÜNTÜLERİNDEN TRANSFORMER TABANLI COVID-19 TESPİTİ***


***Dokumacı, H. Ö. (2024). Transformer tabanlı Covid-19 tespiti: Chest X-ray ile derin öğrenme uygulaması. KSÜ Mühendislik Bilimleri Dergisi, 26(1), 45-60.***

***<http://jes.ksu.edu.tr/tr/download/article-file/3557369>***

Bu çalışma, COVID-19 teşhisinde Vision Transformer (ViT), MaxViT ve Swin Transformer gibi ileri seviye sinir ağlarının performansını değerlendirmektedir. COVID-19'un küresel sağlık üzerindeki etkileri göz önüne alındığında, doğru ve hızlı teşhis yöntemleri büyük önem taşımaktadır. RT-PCR testleri, yüksek doğruluk sunmasına rağmen, zaman alıcı olması ve yanlış negatif sonuçlar üretebilmesi nedeniyle alternatif teşhis yöntemleri üzerinde çalışmalar yürütülmektedir. Bu bağlamda, derin öğrenme tabanlı modellerin özellikle tıbbi görüntüleme alanında sunduğu avantajlar değerlendirilmektedir.

Çalışmada, göğüs röntgeni (CXR) görüntülerini kullanarak COVID-19 tespitini hedefleyen transformer tabanlı sinir ağları incelenmiştir. Geleneksel CNN tabanlı modellerin aksine, ViT tabanlı modeller, küresel bağımlılıkları daha etkili bir şekilde öğrenebilme yeteneğine sahiptir. ViT modeli, görüntüyü küçük parçalara (patch) bölerek her bir parçayı bir gömülü (embedding) vektör olarak temsil eder ve bu bilgiyi kendine dikkat mekanizması (self-attention) kullanarak işler. MaxViT, yerel ve küresel bilgileri birleştiren çok eksenli bir dikkat mekanizması sunarken, Swin Transformer ise kaydırılabilir pencere mekanizmasını kullanarak hesaplama maliyetlerini düşürüp uzamsal bağımlılıkları korur.

Çalışmada kullanılan veri seti, ChestX-ray (CXR) görüntülerinden oluşmakta olup, transfer öğrenme teknikleri uygulanmıştır. Modellerin eğitimi sırasında, veri artırma (augmentation) yöntemleri ile modelin genelleme yeteneği artırılmıştır. Karşılaştırmalı analizlerde, doğruluk (accuracy), duyarlılık (recall) ve kesinlik (precision) gibi metrikler kullanılmıştır. Sonuçlar, Swin Transformer modelinin en yüksek doğruluğa (%98.9) ulaştığını ve hem duyarlılık (%96.5) hem de kesinlik açısından üstün olduğunu göstermektedir. Bu model, yanlış pozitif oranlarını minimize ederek en güvenilir teşhis aracını sunmaktadır.



Şekil-2 – Swin Transformer sonuçlarının Confusion Matrix tablo gösterimi

Sonuç olarak, çalışma ViT tabanlı modellerin COVID-19 teşhisinde etkili olduğunu doğrulamış ve Swin Transformer'ın en iyi performansı sergilediğini ortaya koymuştur. Transformer tabanlı modellerin tıbbi görüntü analizi alanında sunduğu potansiyel, gelecekte daha geniş çaplı çalışmaların yapılmasını gerektirmektedir. Elde edilen bulgular, derin öğrenme tabanlı modellerin tıbbi teşhislerde önemli bir potansiyele sahip olduğunu ve klinik uygulamalara entegre edilebileceğini göstermektedir.